Tech Challenge - Fase 3
Risco de alfabetização municipal

Repositório do projeto: https://github.com/techposrc-ops/Tech_Challenge_Fase_3

Previsão de risco de ficar abaixo da meta

O projeto usa indicadores históricos de alfabetização para estimar o risco de cada município e rede de ensino ficar abaixo da meta no ano seguinte.

Contexto do problema

O enunciado propõe prever se um aluno será alfabetizado. A base Gold disponível reúne indicadores agregados, por isso a previsão é feita por município e rede de ensino. O ranking ajuda a priorizar a revisão dos indicadores com as redes.

Objetivo

Usar os indicadores de 2023 para prever o cumprimento da meta de 2024, avaliar o modelo em um conjunto reservado e aplicar o modelo final aos indicadores de 2024 para estimar o risco em 2025.

Fonte de dados

A Fase 3 parte dos CSVs da camada Gold da Fase 2. A base municipal alimenta a modelagem. As tabelas de UFs e Brasil dão contexto à análise exploratória.

Base em data/gold/	Anos	Registros	Uso
indicadores_municipio.csv	2023 e 2024	10.271	Análise e modelagem
indicadores_uf.csv	2023 e 2024	49	Análise exploratória
indicadores_brasil.csv	2023 a 2025	3	Análise exploratória

Definição do alvo

O treinamento cruza os dois anos pela chave município e rede. Registros com taxa oficial e meta disponíveis em 2024 recebem classe 1 se a taxa ficou abaixo da meta e classe 0 se atingiu ou superou a meta.

Arquitetura da solução

```
CSVs Gold -> análise exploratória -> painel município e rede
          -> comparação de modelos -> avaliação em teste reservado
          -> treinamento final -> modelo Joblib -> ranking CSV
```

Análise e comparação

Notebook 01. Explora cobertura, valores ausentes, taxas e metas por município, UF e Brasil.

Notebook 02. Compara regressão logística, Random Forest e XGBoost e usa SHAP para interpretar as previsões.

Notebook 03. Avalia o Random Forest sem transformação logarítmica no teste reservado. Em seguida, treina com todos os registros rotulados e salva o modelo final.

Variáveis e pré-processamento

O pipeline usa a rede de ensino e seis indicadores do ano anterior: taxa oficial, alunos presentes, percentual de participação, nível de alfabetização, média de proficiência e média de português.

O treinamento preenche ausências numéricas pela mediana e padroniza as variáveis. Para a rede, usa a categoria mais frequente para preencher ausências e aplica codificação one-hot.

Avaliação do modelo escolhido

Métrica no teste reservado	Resultado
Registros no teste	923
Acurácia	61,43%
Recall da classe de risco	62,00%
ROC-AUC	0,6618

No teste de 2024, o modelo identificou cerca de seis em cada dez registros que ficaram abaixo da meta.

Resultado e alcance

Com os indicadores de 2024, o modelo gera 5.449 estimativas para 2025. A Gold municipal disponível termina em 2024. A avaliação em um ano posterior depende dos resultados municipais de 2025.

Como reproduzir a entrega

Ambiente local no Windows

Execute os comandos na raiz do projeto com Python 3.11 ou superior.

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
```

Gerar o ranking com o modelo salvo

```
$python = ".\.venv\Scripts\python.exe"
& $python -m src.predizer --ano-previsao 2025 --saida tmp/ranking_2025.csv
```

O CSV contém município, rede, ano-alvo, probabilidade de risco e classe prevista. Os registros são ordenados por risco decrescente. Probabilidades a partir de 0,50 recebem classe 1.

Treinar uma cópia do modelo

```
& $python -m src.treinar --modelo tmp/modelo.joblib
& $python -m src.predizer --ano-previsao 2025 `
  --modelo tmp/modelo.joblib --saida tmp/ranking_2025_retreino.csv
```

Executar os notebooks

No VS Code, selecione `.venv` como kernel e execute os notebooks na ordem 01, 02 e 03. Na seção 10 do notebook 01, remova a chamada isolada `len()` antes de executar a primeira célula de código. Os notebooks 02 e 03 gravam no mesmo caminho de modelo. Execute o 03 por último para salvar o modelo final.

Arquivos da entrega

Caminho	Conteúdo
data/gold/	Indicadores de Brasil, UFs e municípios
notebooks/	Exploração, experimentos e avaliação
src/	Treinamento e inferência em lote
modelos/risco_alfabetizacao.joblib	Modelo final e pré-processamento
docs/TechChallenge_Fase3.pdf	Enunciado do desafio